

## ИДЕНТИФИКАЦИЯ ДЕФЕКТОВ НА ИЗОБРАЖЕНИЯХ ДОРОЖНОГО ПОКРЫТИЯ С ПОМОЩЬЮ ГЛУБОКИХ СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ

© 2019 г. А. Н. Соловьев<sup>1,2</sup>, Б. В. Соболев<sup>1</sup>, П. В. Васильев<sup>1\*</sup>, А. В. Сеничев<sup>1</sup>

<sup>1</sup> – Донской Государственный Технический Университет, 344010 Ростов-на-Дону, пл. Гагарина 1

<sup>2</sup> – Южный Федеральный Университет, 344090 Ростов-на-Дону, ул. Мильчакова 8А  
\* - lyftzeigen@mail.ru

Предложена модель глубокой сверточной нейронной сети для проведения идентификации дефектов на изображениях дорожного покрытия. Модель реализована как упрощенный и оптимизированный вариант наиболее популярных, на данный момент, FC-сетей. Предложены техники построения обучающей выборки и двухэтапного процесса обучения сети, с учетом специфики решаемой задачи. Прделанная работа показала, что можно успешно применять подобные архитектуры в условиях небольшого количества исходных данных. Предложенная модель имеет высокую степень повторяемости и может быть использована в различных задачах сегментации. Согласно используемым метрикам, сверточная сеть показывает следующие результаты идентификации дефектов: IoU – 0.3488, Dice – 0.7381.

*Ключевые слова:* идентификация дефектов, машинное обучение, сверточные нейронные сети, дорожное покрытие.

### ВВЕДЕНИЕ

Инфраструктуры общественного назначения подвержены естественному процессу старения. В связи с этим требуется проведение более частых процедур контроля. Эффективные стратегии мониторинга состояния могут помочь инженерам в надлежащем планировании работ по обслуживанию и ремонту дорожных покрытий, что приведет к значительному сокращению расходов на обслуживание жизненного цикла дорожного покрытия. Своевременное обнаружение проблемных участков и эффективное управление технического обслуживания гарантируют постоянную доступность объектов инфраструктуры. Оценка критического состояния дорожного покрытия прошла много этапов от применения ручных методов фото-фиксации до использования высокоскоростной цифровой техники [1].

Россия входит в пятерку стран с самой большой протяженностью автомобильных дорог и федеральных магистралей. Для инфраструктур большой протяженности требуются системы мониторинга, которые объединяют в себе простоту использования, высокую скорость, надежность и качество работы.

Для проведения контроля состояния дорожного покрытия могут применяться системы фото и видеонаблюдения. Оценка и анализ собранных данных в ручном режиме может продолжаться очень долго. Поэтому время, необходимое для проведения фактического осмотра и дальнейшей оценки состояния объектов контроля, может превышать срок их эксплуатации.

В данной работе предлагается подход, который задействует технологии машинного

обучения. Это позволяет автоматизировать процесс оценки качества дорожного покрытия. Предлагаемый подход заключается в обучении сверточной нейронной сети на основе данных, размеченных вручную. Таким образом, система научится распознавать основные виды повреждений объектов контроля и проводить их оценку. Это позволит существенно повысить скорость обследования дорожного полотна и сократить материальные издержки.

## ОБЗОР ЛИТЕРАТУРЫ

В последнее время многие исследователи сосредоточили свои усилия на совершенствовании алгоритмов обнаружения дефектов и разработке методов автоматического обнаружения трещин в деталях конструкций и объектах инфраструктуры. Как показала практика, область компьютерного зрения, нацеленная на обнаружение дефектов, постоянно развивается с устойчивым прогрессом в области технологий зондирования, аппаратного и программного обеспечения. Несмотря на это, все еще существуют ограничения, накладываемые на существующие методы и подходы. В области определения дефектов на дорожном покрытии, такими ограничениями могут быть, например, неоднородность самих дефектов, большое разнообразие типов поверхностей, сложность фона, различные примыкания и многое другое.

Большое внимание, в опубликованных работах, уделяется исследованию и разработке автоматизированных методов обнаружения трещин на изображениях [2, 3, 4, 5, 6, 7, 8, 9]. Некоторые из рассматриваемых работ более специфичны, например, [10, 11] в области дорожно-транспортных инфраструктур, [12, 13] в области мостов и сооружений.

До глобального распространения нейросетевых технологий и машинного обучения, поддерживаемого вычислительными мощностями графических процессоров, основной тенденцией являлось применение ручных техник, таких как морфологические операции [13], извлечение геометрических особенностей [6], применение фильтров Габора [14], вейвлет преобразований [15], гистограмм ориентированных градиентов (HOG) [16], текстового анализа и машинного обучения [17].

Сверточная нейронная сеть (СНН) это архитектура искусственной нейронной сети, специально предназначенная для работы с изображениями [18]. СНН это многослойная нейросетевая архитектура, реализующая локальные восприимчивые поля, через сверточные слои и инвариантность относительно малых геометрических деформаций через слой субдискретизации (pooling layer).

Данная архитектура показывает выдающиеся результаты в классической задаче распознавания рукописных цифр [19], в распознавании номеров домов на основе набора данных The Street View House Numbers (SVHN) [20] и в задаче распознавания и

классификации дорожных знаков [21].

Последние открытия в области искусственных сверточных нейронных сетей дали исследователям уникальный инструмент и ряд преимуществ. С ростом вычислительных мощностей графических процессоров стало возможным применять более глубокие архитектуры моделей машинного обучения [22]. Современные техники, такие как, увеличение данных, регуляризация и другие, дали возможность избегать переобучения [23].

С развитием сверточных нейронных сетей, стала доступна возможность более эффективно изучать и обобщать особенности изображений. Это было применено к области, например, классификации изображений [24], поиска объектов [25], обнаружения транспортных средств [26].

Гибкость и перспективность применения глубокого обучения в задачах автоматического обнаружения трещин в дорожном покрытии показана в работах [27, 28, 29].

В работе [30] рассматривается подход автоматического обнаружения трещин на асфальте и их классификация с использованием нейронных сетей. Авторы предложили подход, в котором они делят изображение на фрагменты, и после этого каждая ячейка классифицируется как трещина, используя среднее значение и дисперсию значений оттенков серого. Было показано, что дефлектометры с падающим весом (FWD) являются полезными инструментами для оценки трещин в слое асфальта. В 98 процентах случаев система смогла эффективно обнаружить трещину на изображении.

В работе [31] авторы рассматривали применение нейронной сети для обнаружения дефектов. Они выяснили, что по сравнению с другими методами, кластеризация пикселей как объектов является хорошим способом увеличить точность идентификации и уменьшить шум.

В работе [32] авторы использовали архитектуру глубокого обучения, которая включает предварительно обученную модель VGG-16. Предварительно обученная модель VGG-16 научилась извлекать особенности из изображений, которые могут отличить один класс изображения от другого. Она показала отличное качество распознавания даже в работе с изображениями из ранее не задействованных областей. Урезанный ГСНН VGG-16 используется в качестве глубокого генератора признаков для изображений дорожного покрытия. Авторы обучали только последний слой классификатора. Авторы проводят обширные эксперименты с различными моделями машинного обучения и показывают их сильные и слабые стороны.

В работе [33] представлено применение СНН в прикладной задаче в области

робототехники. Задачей системы является автономное обнаружение и оценка состояния трещин и повреждений в канализационной трубе. СNN выполняет фильтрацию данных, локализуя трещины, что позволяет получить последующую характеристику ее геометрических параметров.

В работе [34] целью является разработка интегрированной модели на основе методов обработки изображений и машинного обучения для автоматизации последовательного обнаружения сколов и численного представления разрушения в сетях метрополитена. Интегрированная модель состоит из гибридного алгоритма, интерактивного 3D-представления и поддерживается регрессионным анализом для прогнозирования глубины сколов.

В работе [35] дается обзор и оценка некоторых перспективных подходов, основанных на концепции автоматического обнаружения трещин и коррозии в системах гражданской инфраструктуры.

В работе [36] представлена эффективная архитектура на основе СNN для обнаружения трещин дорожного покрытия на трехмерной поверхности асфальта. Архитектура CrackNet обеспечивает высокую точность обработки данных, используя оригинальный метод представления геометрии дорожного покрытия. CrackNet состоит из пяти слоев и включает более миллиона параметров, которые проходят подготовку в процессе обучения. Эксперименты с использованием 200 тестовых 3D-изображений показали, что CrackNet может достигать высокой точности (90,13%).

## **МЕТОДИКА ПРОВЕДЕНИЯ ИССЛЕДОВАНИЙ**

Для проведения идентификации дефектов на изображениях дорожного покрытия, нужно определить, что является дефектом, а что нет. Другими словами, нужно провести сегментацию изображения и выделить соответствующие классы. Данный тип задач, в последнее время, эффективно решается с помощью специально разработанных архитектур сверточных нейронных сетей, таких, например, как SegNet [37], U-Net [38].

Изображения дорожного покрытия имеют свою специфику. Она заключается в небольшом диапазоне серого цвета и небольшой разнице между фоном и целевым объектом изображения. Помимо этого, на изображениях могут присутствовать большое количество шумов и посторонних объектов. Изображения могут содержать различные типы дефектов, разного размера и формы.

На данный момент, существует большое количество наборов данных, на основе которых, можно провести обучение нейронной сети [39, 40]. Эти наборы данных включают в себя оригинальные изображения дорожного покрытия и соответствующие им

изображения-маски, показывающие наличие или отсутствие дефектов. Так как изображения с дефектами на дорожном покрытии имеют свою специфику, авторы предлагают собственную упрощенную модель глубокой сверточной нейронной сети. Для сегментации изображения предлагается Fully convolutional neural network [41] со структурой Encoder-Decoder. На вход системы подается изображение дорожного покрытия, а на выходе получается бинарное изображение-маска. Таким образом, в качестве результата, получается сегментированное изображение, показывающее наличие и отсутствие дефектов.

## АРХИТЕКТУРА

На рис. 1 показана архитектура предлагаемой глубокой сверточной нейронной сети. Нейронная сеть стоит из двух частей – сверточной и разверточной. Сверточная часть выполняет функцию извлечения признаков. Она преобразует входное изображение в многомерное представление признаков. Разверточная сеть играет роль генератора, который создает сегментированное изображение на основе признаков, полученных от сверточной сети. Последний сверточный слой сети с сигмовидной активационной функцией генерирует сегментированное изображение, другими словами, карту вероятностей присутствия дефекта. Результирующее сегментированное изображение имеет тот же размер, что и входное изображение.

Первая часть сети состоит из 5 сверточных слоев с наборами фильтров (256, 128, 64, 64, 64). Применяется инструмент batch normalization (BN) [42]. В качестве активационных функций применяется «выпрямитель» rectified linear unit (ReLU). Далее следуют слои субдискретизации (Pooling) с окном 2x2. Таким образом, происходит уменьшение изображения в 2 раза, после его прохождения через этот слой. Вторая часть сети является зеркальным отражением первой части. Для того, чтобы восстановить размер изображения до исходного и сформировать карту вероятностей, на основе признаков входного изображения, применяются upsampling слои в комбинации со сверточными слоями. Предложенная нейронная сеть имеет 10 сверточных слоев и 929 665 обучаемых параметров.




Рис. 1. Архитектура предложенной сети

## ПОДГОТОВКА НАБОРА ДАННЫХ

Для обучения построенной модели используется набор данных CrackForest [39]. Проводится его аугментация (искусственное увеличение набора данных), так как обучение и работа нейронной сети основана на Path-based подходе. Набор данных состоит из 117 изображений. Он разделяется на обучающую, тестовую и валидационную выборки. Для каждого изображения из обучающей и тестовой выборки случайно выбираются фрагменты размером 64x64. Исследования показали, что в рамках поставленной задачи, гамма-коррекция изображений способствует увеличению качества работы нейронной сети. Каждый фрагмент изображения подвергается вращению, отражению и деформации. Было установлено, что наиболее оптимальное соотношение фрагментов с дефектом (дефект занимает не менее 5% площади изображения) и без него составляет соответственно 95% к 5%. Размер выборки влияет на процесс обучения и качество работы сети. Установлено, что оптимальным соотношением является 15200 фрагментов обучающей выборки и 3968 тестовой. На рис. 2 показаны изображения и соответствующие им бинарные маски, применяемые для обучения нейронной сети.




Рис. 2. Изображения и соответствующие им бинарные маски, полученные в результате аугментации данных

## ОБУЧЕНИЕ НЕЙРОННОЙ СЕТИ

В связи со спецификой исследуемого объекта контроля, для обучения и оценки работы нейронной сети применяются метрики intersection over union (IoU, коэффициент Жаккара) и эквивалентная ей бинарная мера схожести dice (мера Сёренсена). В качестве функции потерь используется функция  $1 - J$ .

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}; \quad S(A, B) = \frac{2|A \cap B|}{|A| + |B|} \quad (1)$$

Инициализация весов в слоях нейронной сети осуществляется методом Glorot [43]. Выполняется batch normalization для уменьшения внутреннего ковариационного сдвига путем нормализации входных распределений каждого слоя. Для обучения используется алгоритм оптимизации Adam (Method for Stochastic Optimization) [44].

Обучение нейронной сети проходит в несколько этапов. На первом этапе сеть обучается на небольшом объеме данных (30% от основного набора). Обучение продолжается 5 эпох. На втором этапе сеть обучается на полном объеме данных необходимое количество эпох. Параметр learning rate изменяется с каждой эпохой, согласно установленной зависимости, что показано на рис. 3. В рамках поставленной задачи, было установлено наиболее рациональное количество эпох обучения равное 25 (5 эпох на первом этапе и 20 эпох на втором этапе обучения). При большем количестве эпох точность работы нейронной сети в значительной степени не изменялась.

Для реализации разработанной архитектуры ГСНН используются фреймворки Keras и Tensorflow.

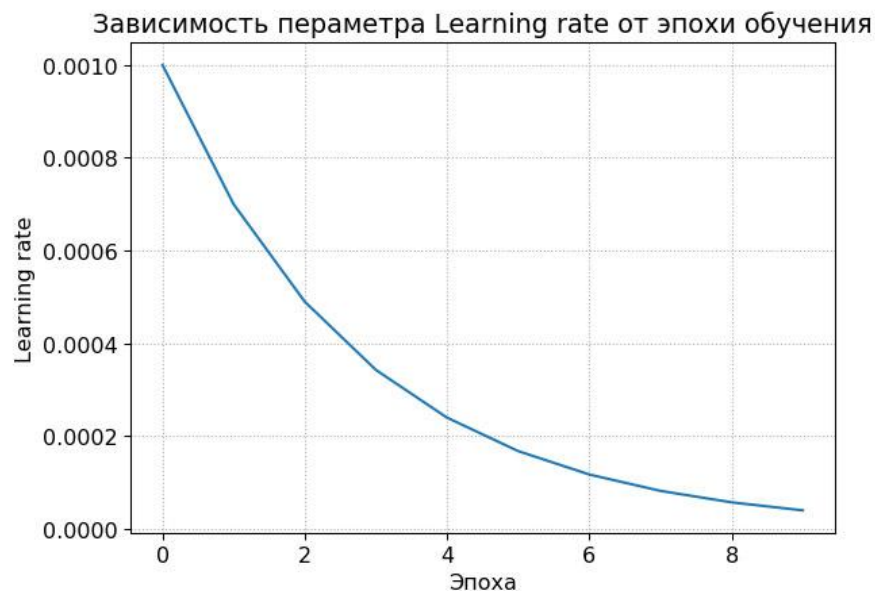


Рис. 3. Изменение параметра learning rate во время обучения сети

## РЕЗУЛЬТАТЫ

После обучения нейронной сети, производится валидация на тестовых данных. Каждый фрагмент изображения подается на вход нейронной сети, а на выходе получается сгенерированная карта вероятностей (маска) наличия дефекта. На рис. 4 продемонстрированы результаты работы обученной сети и их сравнение с истинными значениями из тестовой выборки. Полученная маска сравнивается с истинным значением. В связи со специфическим отношением площади дефекта к площади всего изображения, а также форматов истинной маски и маски, полученной от нейронной сети, метрики IoU и Dice имеют характерные значения. Стоит отметить, что при использовании метрики IoU для фрагментов, на которых отсутствует дефект, значения метрики равны 0, что видно на рис. 5. Чтобы компенсировать эту особенность, необходимо использовать дополнительную метрику Dice. Это позволит в более полной мере оценить работу обученной нейронной сети.

Качество, подготовленного набора данных, оказывает большое влияние на обучение и результат работы нейронной сети. В некоторых случаях, в результате работы нейронной сети, наблюдается наличие дефектов, хотя на истинных изображениях дефект отсутствует (ошибка разметки), или наоборот. Что сказывается на общей оценке качества работы представленной модели. В целом, оценка точности работы нейронной сети, предложенными метриками, может иметь субъективный характер. Поэтому не стоит воспринимать приведенные значения как абсолютные (рис. 4).

В рамках данной работы, была проведена оценка некоторых моделей FCN-нейронных сетей. Результаты приведены в табл. 1. В скобках указано количество фильтров на первой (сверточной) части сети. Количество фильтров на второй части сети



зеркально отражено (рисунок 1). Также указано количество обучаемых параметров, показывающих размер и сложность сети.

Таблица 1.

Точность работы некоторых моделей нейронных сетей

Архитектура сети	Точность работы
10 слоев (256, 128, 64, 64, 64, ...), 929 665 параметров	Dice: <b>73.81%</b> , IoU: <b>34.88%</b>
16 слоев (32, 32, 16, 16, 16, 8, 8, 8, ...), 43 441 параметров	Dice: 70.40%, IoU: 33.24%
12 слоев (32, 32, 16, 16, 8, 8, ...), 37 537 параметров	Dice: 67.57%, IoU: 32.12%




Рис. 4. Результаты работы обученной нейронной сети. В первом столбце показано исследуемое изображение, во втором – результат работы нейронной сети, в третьем – дефект, выделенный человеком вручную, в четвертом - их разница

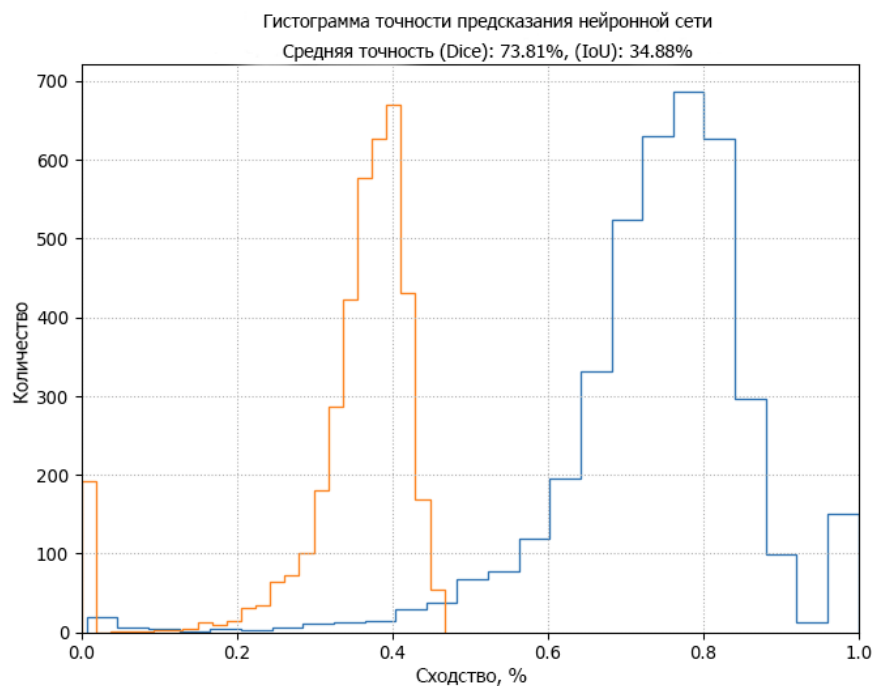


Рис. 5. Количество изображений, идентифицированных с определенной точностью

Для обработки изображений высокого разрешения применяется метод скользящего окна с заданным шагом, регулирующим скорость обработки и детализацию. Таким образом, формируется результирующая карта вероятностей (тепловая карта) наличия дефекта для всего изображения. Несколько изображений из валидационного набора и результат обработки их нейронной сетью представлены на рис. 6.




Рис. 6. Валидационные изображения, обработанные обученной нейронной сетью. В первом столбце реальное изображение с дефектом, во втором – маска дефекта, созданная человеком, в третьем – маска дефекта, сгенерированная нейронной сетью.

## ЗАКЛЮЧЕНИЕ

В данной работе продемонстрирован подход идентификации дефектов на дорожном покрытии с применением модели глубокой сверточной нейронной сети. В связи со спецификой решаемой задачи сегментации дефектов, модель реализована как упрощенный и оптимизированный вариант наиболее популярных, на данный момент, FC-сетей. Для получения наиболее репрезентативной выборки и проведения более тонкой настройки нейронной сети, предложены техники аугментации и двухэтапного процесса обучения. Прделанная работа показала, что возможно успешно применять подобные архитектуры в условиях небольшого количества исходных данных. Предложенная модель имеет высокую степень повторяемости и может быть использована в различных задачах сегментации. В результате, согласно используемым метрикам, FCN показывает следующие результаты: IoU – 0.3488, Dice – 0.7381.

**Работа выполнена при поддержке РФФИ в рамках проектов №18-31-00024 и №19-08-00074.**

## ЛИТЕРАТУРА

1. National Academies of Sciences, Engineering, and Medicine. 2009. Quality Management of Pavement Condition Data Collection. Washington, DC: The National Academies Press.
2. *Mahler, D. S., Kharoufa, Z. B., Wong, E. K. and Shaw, L. G.* (1991), Pavement Distress Analysis Using Image Processing Techniques. Computer-Aided Civil and Infrastructure Engineering, 6: 1-14
3. *Tizhoosh H.R., Krell G., Michaelis B.* (1997) Locally adaptive fuzzy image enhancement. In: Reusch B. (eds) Computational Intelligence Theory and Applications. Fuzzy Days 1997. Lecture Notes in Computer Science, vol 1226. Springer, Berlin, Heidelberg.
4. *Zou, Qin & Cao, Yu & Li, Qingquan & Mao, Qingzhou & Wang, Song.* (2012). Crack Tree: Automatic crack detection from pavement images. Pattern Recognition Letters. 33. 227-238.
5. *W. Xu, Z. Tang, J. Zhou and J. Ding,* "Pavement crack detection based on saliency and statistical features," 2013 IEEE International Conference on Image Processing, Melbourne, VIC, 2013, pp. 4093-4097.
6. *Oliveira, Henrique & Correia, Paulo.* (2014)., CrackIT - An Image Processing Toolbox for Crack Detection and Characterization. 2014 IEEE International Conference on Image Processing, ICIP 2014.
7. *Shi, Yong & Cui, Limeng & Qi, Zhiquan & Meng, Fan & Chen, Zhensong.* (2016). Automatic Road Crack Detection Using Random Structured Forests. IEEE Transactions on Intelligent Transportation Systems. 17. 1-12.

8. Lee, B. J. and Lee, H. “. (2004), Position-Invariant Neural Network for Digital Pavement Crack Analysis. *Computer-Aided Civil and Infrastructure Engineering*, 19: 105-118.
9. Sun, Bo-Cheng & Qiu, Yan-jun. (2007). Automatic Identification of Pavement Cracks Using Mathematic Morphology.
10. S. Chambon. Detection of road cracks with multiple images. In *International Joint Conference on Computer Vision Theory and Applications, VISAPP*, 2010.
11. Zhang, Lei & Yang, Fan & Zhang, Yimin & Julie Zhu, Ying. (2016). Road crack detection using deep convolutional neural network.
12. Prasanna, Prateek & Dana, Kristin & Gucunski, Nenad & Basily, Basily & La, Hung & Lim, Ronny & Parvardeh, Hooman & Gucunski, N & Basily, B. (2014). Automated Crack Detection on Concrete Bridges. *IEEE Transactions on Automation Science and Engineering*. 1-9.
13. Jahanshahi, M.R., Masri, S.F., Padgett, C.W. et al. *Machine Vision and Applications* (2013) 24: 227.
14. Medina, Roberto & Llamas, Jose & Zalama, Eduardo & Gómez-García-Bermejo, Jaime. (2015). Enhanced automatic detection of road surface cracks by combining 2D/3D image processing techniques. *2014 IEEE International Conference on Image Processing, ICIP 2014*. 778-782.
15. Chanda S. et al. (2014) Automatic Bridge Crack Detection – A Texture Analysis-Based Approach. In: El Gayar N., Schwenker F., Suen C. (eds) *Artificial Neural Networks in Pattern Recognition. ANNPR 2014. Lecture Notes in Computer Science*, vol 8774. Springer, Cham.
16. Kapela, Rafal & Rydzewski, Paweł & Michał, Wyczalek & Błoch, Adam & Śniatała, Paweł & Pożarycki, Andrzej & Rybarczyk, Adam & Turkot, Adam. (2015). Asphalt Surfaced Pavement Cracks Detection Based on Histograms of Oriented Gradients.
17. Qin Zou, Yu Cao, Qingquan Li, Qingzhou Mao, Song Wang, CrackTree: Automatic crack detection from pavement images, *Pattern Recognition Letters*, Volume 33, Issue 3, 2012, Pages 227-238.
18. LeCun, Y., Bottou, L., Bengio, Y., Haffner, P.: Gradient-based learning applied to document recognition. *Proceedings of the IEEE* 86(11), 2278–2324 (1998).
19. Ciresan, D., Meier, U., Schmidhuber, J.: Multi-column deep neural networks for image classification. In: *Proc. of Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 3642–3649 (June 2012).
20. Goodfellow, I.J., Bulatov, Y., Ibarz, J., Arnoud, S., Shet, V.: Multi-digit number recognition from street view imagery using deep convolutional neural networks. In: *Proc. of International Conference on Learning Representations (ICLR)* April 2014.

21. *Ciresan, D., Meier, U., Masci, J., Schmidhuber, J.*: A committee of neural networks for traffic sign classification. In: Proc. of International Joint Conference on Neural Networks (IJCNN), pp. 1918–1921 (July 2011).
22. *Arel, I., Rose, D.C., Karnowski, T.P.*: Deep machine learning - a new frontier in artificial intelligence research. IEEE Computational Intelligence Magazine 5(4), 13–18 (2010).
23. *Simard, P.Y., Steinkraus, D., Platt, J.C.*: Best practices for convolutional neural networks applied to visual document analysis. In: Proc. of International Conference on Document Analysis and Recognition (ICDAR), pp. 958–963 (2003).
24. *C. Szegedy et al.*, "Going deeper with convolutions," 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Boston, MA, 2015, pp. 1-9.
25. *R. Girshick, J. Donahue, T. Darrell and J. Malik*, "Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation," 2014 IEEE Conference on Computer Vision and Pattern Recognition, Columbus, OH, 2014, pp. 580-587.
26. *X. Chen, S. Xiang, C. L. Liu and C. H. Pan*, "Vehicle Detection in Satellite Images by Hybrid Deep Convolutional Neural Networks," in IEEE Geoscience and Remote Sensing Letters, vol. 11, no. 10, pp. 1797-1801, Oct. 2014.
27. *L. Some*, Automatic image-based road crack detection methods, KTH Royal Institute of Technology, Stockholm, Sweden, 2016.
28. *D. Xie, L. Zhang, L. Bai*, Deep learning in visual computing and signal processing, Appl. Comput. Intell. Soft Comput. 2017.
29. *Danfeng Xie, Lei Zhang, and Li Bai*, "Deep Learning in Visual Computing and Signal Processing," Applied Computational Intelligence and Soft Computing, vol. 2017, Article ID 1320780, 13 pages, 2017.
30. *T. Saar and O. Talvik*, "Automatic Asphalt pavement crack detection and classification using Neural Networks," 2010 12th Biennial Baltic Electronics Conference, Tallinn, 2010, pp. 345-348.
31. *D. Meignen, M. Bernadet and H. Briand*, "One application of neural networks for detection of defects using video data bases: identification of road distresses," Database and Expert Systems Applications, 1997. Proceedings., Eighth International Workshop on, Toulouse, France, 1997, pp. 459-464.
32. *Kasthurirangan Gopalakrishnan, Siddhartha K. Khaitan, Alok Choudhary, Ankit Agrawal*, Deep Convolutional Neural Networks with transfer learning for computer vision-based data-driven pavement distress detection, Construction and Building Materials, Volume 157, 2017, Pages 322-330.

33. *Browne M., Ghidary S.S. (2003) Convolutional Neural Networks for Image Processing: An Application in Robot Vision. In: Gedeon T.D., Fung L.C.C. (eds) AI 2003: Advances in Artificial Intelligence. AI 2003. Lecture Notes in Computer Science, vol 2903. Springer, Berlin, Heidelberg.*
34. *Thikra Dawood, Zhenhua Zhu, Tarek Zayed, Machine vision-based model for spalling detection and quantification in subway networks, Automation in Construction, Volume 81, 2017, Pages 149-160.*
35. *Mohammad R. Jahanshahi , Jonathan S. Kelly , Sami F. Masri & Gaurav S. Sukhatme (2009) A survey and evaluation of promising approaches for automatic image-based defect detection of bridge structures, Structure and Infrastructure Engineering: Maintenance, Management, Life-Cycle Design and Performance, 5:6, 455-486.*
36. *Zhang, A., Wang, K. C., Li, B., Yang, E., Dai, X., Peng, Y., Fei, Y., Liu, Y., Li, J. Q. and Chen, C. (2017), Automated Pixel-Level Pavement Crack Detection on 3D Asphalt Surfaces Using a Deep-Learning Network. Computer-Aided Civil and Infrastructure Engineering, 32: 805-819.*
37. *V. Badrinarayanan, A. Kendall and R. Cipolla, "SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 39, no. 12, pp. 2481-2495, Dec. 1 2017.*
38. *Ronneberger O., Fischer P., Brox T. (2015) U-Net: Convolutional Networks for Biomedical Image Segmentation. In: Navab N., Hornegger J., Wells W., Frangi A. (eds) Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. MICCAI 2015. Lecture Notes in Computer Science, vol 9351. Springer, Cham.*
39. *Y. Shi, L. Cui, Z. Qi, F. Meng and Z. Chen, "Automatic Road Crack Detection Using Random Structured Forests," in IEEE Transactions on Intelligent Transportation Systems, vol. 17, no. 12, pp. 3434-3445, Dec. 2016.*
40. *Eisenbach, M., Stricker, R., Seichter, D., Amende, K., Debes, K., Sesselmann, M., Ebersbach, D., Stöckert, U., Gross, H.-M. How to Get Pavement Distress Detection Ready for Deep Learning? A Systematic Approach. in: Int. Joint Conf. on Neural Networks (IJCNN), Anchorage, USA, pp. 2039-2047, IEEE 2017.*
41. *E. Shelhamer, J. Long and T. Darrell, "Fully Convolutional Networks for Semantic Segmentation," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 39, no. 4, pp. 640-651, April 1 2017.*
42. *S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," CoRR, vol. abs/1502.03167, 2015.*

43. *Glorot, Xavier and Yoshua Bengio.* “Understanding the difficulty of training deep feedforward neural networks.” AISTATS (2010).
44. *Kingma, Diederik & Ba, Jimmy.* (2014). Adam: A Method for Stochastic Optimization. International Conference on Learning Representations.